



Tecnológico Nacional de México
Campus Querétaro
Instituto Tecnológico de Querétaro
Presenta:

Nombre	Número de control
Baxin Cruz Angela Ivonne	22140631
Piedra Moreno Luis Angel	C18141014
Prado Rivera Dana Paola	21140658
Reyes Cruz Tania Lizbeth	22140615
Vega Hernandez Adriana	21141181
Sayuri	

Ingeniera en Gestión Empresarial.

Inscritos en:

Materia	Grupo
Gestión del Capital Humano	7A

Docente:

Sandra Lucia de la Fuente Bermudez

Trabajo:

**Entrega de proyecto de predicción de resultados en
torneo NCAA**

Fecha de entrega:

Santiago de Querétaro a 20 de Mayo del 2026

InMarch Machine Learning Mania 2026

1. Introducción

La analítica de datos y el aprendizaje automático han revolucionado la manera en que se interpretan los eventos deportivos, permitiendo desarrollar modelos predictivos capaces de analizar grandes volúmenes de información histórica para generar estimaciones probabilísticas de alta precisión.

En este contexto, el presente proyecto fue desarrollado para participar en la competencia internacional “March Machine Learning Mania 2026”, organizada alrededor del torneo de baloncesto universitario de la NCAA. El reto principal consiste en predecir los resultados de los partidos del torneo utilizando técnicas avanzadas de ciencia de datos, estadística y machine learning.

A diferencia de los modelos tradicionales enfocados únicamente en determinar un ganador, el sistema desarrollado busca estimar probabilidades calibradas para cada enfrentamiento. Esto implica que el modelo no solamente predice quién tiene más posibilidades de ganar, sino también qué tan confiable es dicha predicción.

El proyecto integra metodologías de Ingeniería de Datos, Feature Engineering, modelos de Ensemble Learning y validación temporal para construir una solución robusta, escalable y competitiva frente a modelos de nivel internacional.

2. Objetivo General

Desarrollar un sistema inteligente basado en técnicas de Machine Learning capaz de predecir probabilísticamente los resultados del torneo NCAA 2026, minimizando la métrica Log Loss y garantizando estabilidad estadística mediante procesos avanzados de validación y calibración.

3. Objetivos Específicos

- Recolectar y consolidar datos históricos de la NCAA desde 1985 hasta 2025.
- Implementar procesos de limpieza y transformación de datos.
- Diseñar variables predictivas mediante técnicas de Feature Engineering.
- Construir modelos de Machine Learning utilizando algoritmos de boosting.
- Aplicar métodos de Ensemble Learning para mejorar la precisión.
- Validar el desempeño del modelo mediante validación temporal cruzada.
- Optimizar las probabilidades finales para reducir la pérdida logarítmica.

4. Marco Teórico

4.1 Machine Learning en el Deporte

El Machine Learning permite identificar patrones ocultos en grandes volúmenes de datos deportivos. En competencias como la NCAA, donde existen miles de partidos históricos y múltiples variables influyentes, estas técnicas ofrecen ventajas significativas sobre los métodos estadísticos tradicionales.

Los modelos predictivos deportivos utilizan información relacionada con:

- Rendimiento histórico de equipos.
- Diferenciales ofensivos y defensivos.
- Ritmo de juego.
- Ranking competitivo.
- Probabilidad de victoria.
- Tendencias de rendimiento.

4.2 Ensemble Learning

El Ensemble Learning consiste en combinar múltiples modelos predictivos para obtener mejores resultados que utilizando un único algoritmo.

En este proyecto se implementó una arquitectura tipo Stacking, integrando:

- Regresión Logística.
- XGBoost.
- LightGBM.

La combinación de estos modelos permitió mejorar la estabilidad del sistema y reducir el riesgo de sobreajuste.

4.3 Sistema Elo

El sistema Elo es un método dinámico utilizado para medir la fuerza competitiva de un equipo.

Cada partido modifica el puntaje Elo dependiendo de:

- Resultado del encuentro.
- Diferencia esperada.
- Calidad del oponente.
- Ventaja de localía.

Este sistema fue una de las variables más importantes dentro del modelo debido a su capacidad para representar el rendimiento reciente de los equipos.

5. Metodología

El desarrollo del sistema se realizó mediante una arquitectura estructurada en distintas etapas.

5.1 Recolección de Datos

Se recopilaron datos históricos oficiales de la NCAA correspondientes al periodo 1985–2025.

Las principales fuentes de información incluyeron:

- Resultados de temporada regular.
- Resultados de torneos NCAA.
- Seeds del torneo.
- Rankings Massey.
- Métricas avanzadas de eficiencia.

5.2 Limpieza y Transformación

Los datos fueron procesados para eliminar inconsistencias y preparar la información para el entrenamiento.

Entre las tareas realizadas destacan:

- Eliminación de valores nulos.
- Homologación de nombres de equipos.
- Conversión de formatos.
- Normalización de métricas.
- Integración de múltiples bases de datos.

5.3 Ingeniería de Características

La etapa de Feature Engineering fue fundamental para aumentar el desempeño predictivo.

Las principales variables desarrolladas fueron:

a) Calificaciones Elo

Se calcularon ratings dinámicos para cada equipo utilizando:

- Factor $K = 20$.
- Regresión a la media = 0.6.
- Ajuste por localía.

b) Diferenciales de Eficiencia

Se analizaron métricas ofensivas y defensivas considerando:

- Puntos por posesión.
- Ritmo de juego.
- Diferencial ofensivo.
- Diferencial defensivo.

c) Rankings Massey

Se integraron más de 60 sistemas de ranking diferentes para representar perspectivas estadísticas y expertas sobre el desempeño de los equipos.

5.4 Entrenamiento del Modelo

Se implementaron modelos de Gradient Boosting y clasificación probabilística.

Modelos utilizados:

ModeloFunción

Regresión Logística

Base lineal estable

XGBoost

Captura relaciones complejas

LightGBM

Optimización eficiente y rápida

Posteriormente, los modelos fueron integrados mediante una arquitectura de Stacking.

5.5 Validación Temporal

Para evitar Data Leakage y Overfitting se utilizó una validación tipo Expanding Window.

El proceso consistió en:

- Entrenar el modelo con temporadas anteriores.
- Validar de manera independiente las temporadas 2022–2025.
- Repetir el proceso de forma incremental.

Esta metodología permitió simular condiciones reales del torneo NCAA.

6. Métricas de Evaluación

La principal métrica utilizada fue el Log Loss.

6.1 Log Loss

El Log Loss evalúa la calidad de las probabilidades generadas por el modelo.

Un valor cercano a 0 indica predicciones altamente precisas y bien calibradas.

7. Resultados

Los resultados obtenidos demostraron un desempeño sólido y consistente.

Principales hallazgos:

- El sistema Elo fue la característica más influyente.
- Los modelos de boosting mejoraron significativamente la precisión.
- La arquitectura Ensemble incrementó la estabilidad del sistema.

El sistema alcanzó un desempeño competitivo con objetivos de Log Loss menores a 0.55.

8. Dashboard y Visualización

Se desarrolló un Dashboard de Ingeniería de Datos para analizar el comportamiento del modelo.

El dashboard permitió:

- Visualizar probabilidades finales.
- Analizar métricas de desempeño.
- Comparar rankings.
- Detectar posibles anomalías.
- Validar calibración estadística.

La herramienta facilitó la interpretación de resultados y la toma de decisiones durante el proceso de optimización.

9. Conclusiones

El proyecto desarrollado para NCAA March Machine Learning Mania 2026 demuestra cómo la Ingeniería de Datos y el Machine Learning pueden aplicarse exitosamente al análisis deportivo.

La combinación de sistemas Elo, rankings Massey, métricas avanzadas y modelos de boosting permitió construir una herramienta altamente competitiva para la predicción probabilística de partidos.

Además, la implementación de técnicas de validación temporal y calibración estadística garantizó la robustez del modelo frente a escenarios reales de incertidumbre.

El sistema no solo predice resultados, sino que también interpreta la probabilidad real de cada evento, proporcionando una ventaja analítica importante dentro de competencias de ciencia de datos deportivas.